



激活函数

概念定义

激活函数是神经网络中用于引入非线性因素的函数。它决定了神经元是否应该被激活，即对输入信息进行“过滤”或“转换”。没有激活函数，神经网络将只能表达线性映射，其表达能力将大大受限。通过使用激活函数，可以使得深层神经网络能够学习和表示更加复杂的函数。

常见激活函数及其特点

Sigmoid函数

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}}$$

- 优点：输出值 (0, 1) 之间，适合用于二分类问题的概率输出。
- 缺点：(1) 当输入值很大或很小时，梯度接近于0，导致梯度消失问题，影响模型训练速度和效果。(2) 不是0中心的，这会导致网络中的梯度更新偏向某个方向，影响训练效率。(3) 涉及指数运算，计算成本较高，尤其是在大规模数据集上。
- 应用场景：二分类问题的输出层(如逻辑回归)。

Softmax 函数

$$\text{Softmax}(x_i) = \frac{e^{x_i}}{\sum_{j=1}^n e^{x_j}}$$

- 优点：特别适用于多分类问题，可以将多个神经元的输出转化为概率分布。
- 缺点：计算成本较高，尤其是在处理高维数据时。
- 应用场景：多分类问题的输出层。

Tanh (双曲正切)函数

$$\text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

- 优点：输出值的范围是[-1, 1]，相比于Sigmoid，其均值接近于零，有助于解决梯度消失的

问题。

- 缺点：和Sigmoid类似，当输入值很大或很小时，梯度接近于0，也会遇到梯度消失的问题。
- 应用场景：隐藏层(尤其是需要对称输出时)。

ReLU (Rectified Linear Unit) 函数

$$f(x) = \max(0, x)$$

- 优点：(1) 计算简单快速，能加速网络训练过程。(2) 解决了梯度消失的问题，因为对于正值，它的导数为1。
- 缺点：存在“死亡ReLU”问题，对于负值，它的导数为0，这可能导致某些神经元永远不会被激活，即在训练过程中这部分网络无法学习。
- 应用场景：隐藏层，尤其是深层网络，大多数隐藏层的默认选择。

Leaky ReLU 函数

$$f(x) = \max(\alpha x, x)$$

其中， α 是一个取值很小的常数。

- 优点：解决了ReLU的“死亡神经元”问题，因为它允许负输入有一个很小的梯度。
- 缺点：相比ReLU增加了计算复杂度，并且需要选择合适的 α 值。
- 应用场景：隐藏层，尤其是在ReLU表现不佳时，可尝试Leaky ReLU。

ELU (Exponential Linear Unit) 函数

$$f(x) = x, \text{ if } x > 0$$

$$f(x) = \alpha(e^x - 1), \text{ if } x \leq 0$$

- 优点：(1) 解决了ReLU的“死亡神经元”问题，并且相比于Leaky ReLU，它允许负输入有一个更大的梯度。(2) 收敛速度比ReLU更快。
- 缺点：计算成本较高(涉及指数运算)。
- 应用场景：隐藏层，需要快速收敛且计算资源充足时。

SiLU (Sigmoid Linear Unit) 激活函数

$$\text{SiLU}(x) = x \cdot \frac{1}{1 + e^{-x}}$$

可以看出，SiLU对输入进行加权缩放，权重由 Sigmoid 函数决定。这种设计使得 SiLU 具有平滑性和非线性特性。

- **优点：**(1) SiLU 的导数在大部分区域都不为 0，尤其是在负值区域也有梯度存在，因此不会出现像 ReLU 那样的“死亡”问题。(2) 相比 Sigmoid 和 Tanh，SiLU 更不容易出现梯度消失问题，因为它没有将输出严格限制在一个小范围内。(3) SiLU 是平滑的，这意味着它的梯度变化较为连续，适合基于梯度的优化算法(如 SGD、Adam 等)。相比之下，ReLU 在 $x = 0$ 处不可导，可能导致优化过程中的不稳定。(4) SiLU 的非线性和平滑性使其能够更好地拟合复杂的数据分布，从而提高模型的表达能力。(5) 在深层网络中，SiLU 能够更有效地传播梯度，减少梯度消失或爆炸的风险，从而提升训练效果。
- **缺点：**(1) SiLU 的计算涉及指数运算，相比 ReLU 等简单激活函数，计算复杂度更高，增加训练时间。(2) 由于 SiLU 的计算需要浮点运算，可能对某些低精度硬件(如嵌入式设备)不太友好。(3) 虽然 SiLU 本身没有超参数，但它对初始化方式和优化器的选择可能更敏感，需要更多的调参经验。
- **应用场景：**隐藏层，高性能需求的任务(如深度学习竞赛)。